

Лабораторная работа №4

Сопряженные направления и методы Ньютона

Дмитрий Коваль, Георгий Лаврентьев
группа М3232

2 июня 2026 г.

1 Постановка задачи

Рассматривается задача безусловной минимизации

$$\min_{x \in \mathbb{R}^n} f(x),$$

где $f: \mathbb{R}^n \rightarrow \mathbb{R}$ — дважды непрерывно дифференцируемая функция.

В работе реализованы и исследованы методы сопряжённых направлений, методы Ньютона, метод доверительной области и квазиньютоновские методы:

1. метод сопряжённых градиентов для квадратичных функций (линейный CG);
2. нелинейный метод сопряжённых градиентов Флетчера–Ривса (FR);
3. нелинейный метод сопряжённых градиентов Полака–Рибьера (PR);
4. метод Ньютона с разложением Холецкого;
5. метод Ньютона с выбором направления (с регуляризацией гессиана);
6. метод Powell’s Dog Leg (доверительная область);
7. квазиньютоновские методы DFP, BFGS и L-BFGS.

В качестве эталона используется библиотечная реализация `scipy.optimize.minimize(..., method=...)`.

Единый интерфейс и подсчёт затрат. Все собственные методы имеют единую сигнатуру запуска

$$\text{optimizer}(f, \nabla f, H_f, x_0, \varepsilon, \text{max_iter}) \longrightarrow \text{OptResult},$$

и возвращают единую структуру результата `OptResult`, содержащую найденную точку x^* , значение $f(x^*)$ и пять учётных величин, требуемых заданием:

1. число итераций;
2. число вычислений функции f ;
3. число вычислений градиента ∇f ;
4. число вычислений матрицы Гессе H_f (если метод её использует);

5. причину остановки метода.

Подсчёт вызовов оракулов реализован прозрачно через декоратор-счётчик `CallCounter`, оборачивающий f , ∇f и H_f . Все векторно-матричные операции выполнены средствами NumPy.

Критерий остановки и причины остановки. В качестве основного критерия сходимости во всех экспериментах зафиксировано

$$\|\nabla f(x_k)\| \leq \varepsilon, \quad \varepsilon = 10^{-8}.$$

Помимо сходимости по градиенту, методы возвращают и другие причины остановки, что прямо требуется заданием. Используемые статусы:

- *Сходимость по градиенту* — выполнено $\|\nabla f(x_k)\| \leq \varepsilon$;
- *Стагнация по функции* — относительное изменение значения функции за шаг опустилось ниже уровня машинного шума, $|f(x_{k+1}) - f(x_k)| \leq 10^{-14} (1 + |f(x_k)|)$, дальнейший прогресс невозможен;
- *Достигнут лимит итераций* — исчерпан бюджет `max_iter`;
- *Гессиан не положительно определён* — разложение Холецкого невозможно (метод Ньютона по Холецкому);
- *Направление неположительной кривизны* — $p^\top A p \leq 0$ (линейный CG);
- *Стагнация: малый радиус доверия* — радиус доверительной области сжался ниже 10^{-12} (Dog Leg).

2 Общая схема и одномерный поиск

2.1 Общая схема методов спуска

Определение 2.1 (Общая схема метода спуска). Пусть выбрана начальная точка x_0 . Итерационный процесс $\{x_k\}_{k=0}^\infty$ имеет форму *метода спуска*, если

$$x_k = x_{k-1} + \alpha_k p_k, \quad k \in \mathbb{N},$$

где $p_k \in \mathbb{R}^n$ — направление движения на k -й итерации, а $\alpha_k \geq 0$ — длина шага.

Все методы данной работы укладываются в эту схему и различаются *способом выбора направления* p_k : антиградиент с поправкой на историю (сопряжённые градиенты), ньютоновское направление $-H_f^{-1}\nabla f$ (методы Ньютона), направление внутри доверительной области (Dog Leg) или квазиньютоновское направление $-H_k \nabla f$ с приближённой обратной матрицей Гессе H_k . Вектор p_k называется **направлением спуска**, если $\langle \nabla f(x_{k-1}), p_k \rangle < 0$; тогда при достаточно малом шаге функция гарантированно убывает.

2.2 Одномерный поиск: условия Армихо и Вольфе

Для методов FR, PR, DFP, BFGS и L-BFGS длина шага α_k вдоль направления p_k подбирается одномерным поиском. Используются два классических условия приемлемости шага.

Определение 2.2 (Условие Армихо). Для направления p_k условие достаточного убывания (Армихо) имеет вид

$$f(x_{k-1} + \alpha p_k) \leq f(x_{k-1}) + c_1 \alpha \langle \nabla f(x_{k-1}), p_k \rangle, \quad c_1 \in (0, 1).$$

Определение 2.3 (Сильные условия Вольфе). Сильные условия Вольфе состоят из условия Армихо и условия кривизны:

$$\begin{aligned} f(x_{k-1} + \alpha p_k) &\leq f(x_{k-1}) + c_1 \alpha \langle \nabla f(x_{k-1}), p_k \rangle, \\ |\langle \nabla f(x_{k-1} + \alpha p_k), p_k \rangle| &\leq c_2 |\langle \nabla f(x_{k-1}), p_k \rangle|, \quad 0 < c_1 < c_2 < 1. \end{aligned}$$

Условие кривизны запрещает слишком короткий шаг: оно требует, чтобы производная функции вдоль луча в новой точке заметно уменьшилась по модулю.

Замечание 2.1. Чистое дробление шага ($\alpha \leftarrow q\alpha$) согласовано с условием Армихо, но, вообще говоря, не обязано удовлетворять второму условию Вольфе. Поэтому Вольфе-поиск реализован отдельной двухэтапной процедурой **bracketing–zoom**: на первом этапе интервал $[\alpha_{lo}, \alpha_{hi}]$ зажимает подходящий шаг (когда нарушено условие Армихо либо производная вдоль луча сменила знак), на втором — интервал сужается делением пополам до выполнения сильных условий Вольфе. Именно эта процедура (Алгоритм 3.5–3.6 Nocedal & Wright) используется в коде и обеспечивает корректный шаг для квазиньютоновских методов и нелинейного CG. Для метода Ньютона с выбором направления, где ньютоновский шаг уже близок к единичному, достаточно более дешёвого дробления по Армихо.

3 Описание методов

3.1 Сопряжённые градиенты для квадратичной функции

Пусть $f(x) = \frac{1}{2} \langle x, Ax \rangle - \langle b, x \rangle + c$, $A = A^\top \succ 0$. Градиент $\nabla f(x) = Ax - b$, и невязка $r_k = b - Ax_k = -\nabla f(x_k)$.

Определение 3.1 (A -сопряжённость). Векторы p_i, p_j называются A -сопряжёнными, если $\langle p_i, Ap_j \rangle = 0$ при $i \neq j$.

Метод строит направления, A -сопряжённые между собой, и минимизирует f вдоль каждого из них *точно*. Расчётные формулы:

$$\begin{aligned} p_0 &= -g_0, \quad \alpha_k = \frac{\langle g_k, g_k \rangle}{\langle p_k, Ap_k \rangle}, \quad x_{k+1} = x_k + \alpha_k p_k, \\ g_{k+1} &= g_k + \alpha_k Ap_k, \quad \beta_k = \frac{\langle g_{k+1}, g_{k+1} \rangle}{\langle g_k, g_k \rangle}, \quad p_{k+1} = -g_{k+1} + \beta_k p_k. \end{aligned}$$

Обновление градиента $g_{k+1} = g_k + \alpha_k Ap_k$ не требует отдельного вызова оракула, а матрица $A = H_f$ вычисляется один раз. Если встречается направление неположительной кривизны $\langle p_k, Ap_k \rangle \leq 0$ (для $A \succ 0$ невозможно, но защищает от потери знакоопределённости при применении к неквадратичным моделям), метод останавливается.

Теорема 3.1 (Конечная сходимость). Для $f(x) = \frac{1}{2} \langle x, Ax \rangle - \langle b, x \rangle + c$ с $A \succ 0$ метод сопряжённых градиентов находит точный минимум не более чем за n итераций. Скорость сходимости управляется числом обусловленности:

$$\|x_k - x^*\|_A \leq 2 \left(\frac{\sqrt{\kappa} - 1}{\sqrt{\kappa} + 1} \right)^k \|x_0 - x^*\|_A, \quad \kappa = \text{cond}(A).$$

3.2 Нелинейные сопряжённые градиенты: FR и PR

Для произвольной гладкой f невозможно вычислить α_k аналитически и обновлять градиент по формуле невязки. Поэтому α_k ищется сильными условиями Вольфе, $g_k = \nabla f(x_k)$ вычисляется напрямую, а коэффициент β_k берётся в одной из двух форм:

$$\beta_k^{\text{FR}} = \frac{\langle g_{k+1}, g_{k+1} \rangle}{\langle g_k, g_k \rangle} \quad (\text{Флетчер–Ривс}),$$

$$\beta_k^{\text{PR}} = \max \left(0, \frac{\langle g_{k+1}, g_{k+1} - g_k \rangle}{\langle g_k, g_k \rangle} \right) \quad (\text{Полак–Рибьер, вариант PR}^+).$$

Усечение $\max(0, \cdot)$ в PR обеспечивает автоматический рестарт направления и глобальную сходимость. Дополнительно после каждого обновления проверяется, что p_{k+1} — направление спуска: если $\langle g_{k+1}, p_{k+1} \rangle \geq 0$, направление сбрасывается на антиградиент $p_{k+1} = -g_{k+1}$.

3.3 Метод Ньютона с разложением Холецкого

Ньютоновское направление получается из квадратичной модели и удовлетворяет системе

$$H_f(x_k) p_k = -\nabla f(x_k), \quad x_{k+1} = x_k + p_k.$$

Так как вблизи минимума $H_f \succ 0$, система решается **разложением Холецкого** $H_f = LL^\top$ (через `scipy.linalg.cho_factor / cho_solve`). Если H_f не является положительно определённой, разложение Холецкого невозможно — метод останавливается со статусом «Гессиан не положительно определён». Это и есть требуемое заданием поведение немодифицированного метода Ньютона.

Теорема 3.2 (Квадратичная сходимость). Если f дважды непрерывно дифференцируема, $H_f(x^*) \succ 0$ и H_f липшицева, то вблизи x^* метод Ньютона с единичным шагом сходится квадратично: $\|x_{k+1} - x^*\| \leq C \|x_k - x^*\|^2$. Для квадратичной функции минимум достигается за один шаг.

3.4 Метод Ньютона с выбором направления

Чтобы сделать метод устойчивым к неположительной определённости гессиана, направление выбирается из *регуляризованной* системы. Вычисляются собственные значения $H_f(x_k)$; если $\lambda_{\min} \leq \delta$ (порог $\delta = 10^{-4}$), матрица сдвигается:

$$\tilde{H} = H_f(x_k) + (\delta' - \lambda_{\min}) I \succ 0, \quad \tilde{H} p_k = -\nabla f(x_k).$$

Длина шага вдоль p_k подбирается дроблением по Армихо. Такой метод не прерывается на седловых и невыпуклых участках, а гарантированно даёт направление спуска.

3.5 Powell's Dog Leg (доверительная область)

Метод доверительной области на каждом шаге минимизирует квадратичную модель

$$m_k(p) = f(x_k) + \langle \nabla f(x_k), p \rangle + \frac{1}{2} \langle p, B_k p \rangle \quad \text{при} \quad \|p\| \leq \Delta_k,$$

где Δ_k — радиус доверия. Решение аппроксимируется ломаной *dog leg*, соединяющей точку Коши (минимум модели вдоль антиградиента)

$$p^C = -\tau \frac{\Delta_k}{\|g_k\|} g_k, \quad \tau = \min \left(1, \frac{\|g_k\|^3}{\Delta_k \langle g_k, B_k g_k \rangle} \right),$$

и ньютоновскую точку $p^N = -B_k^{-1} g_k$:

$$p = \begin{cases} p^N, & \|p^N\| \leq \Delta_k, \\ \Delta_k p^C / \|p^C\|, & \|p^C\| \geq \Delta_k, \\ p^C + t(p^N - p^C), & \text{иначе, } \|p\| = \Delta_k. \end{cases}$$

Радиус обновляется по коэффициенту согласия модели и функции $\rho = \frac{f(x_k) - f(x_k + p)}{m_k(0) - m_k(p)}$:

$$\rho < 0.25 \Rightarrow \Delta \leftarrow 0.25 \Delta; \quad \rho > 0.75 \text{ и шаг на границе} \Rightarrow \Delta \leftarrow \min(2\Delta, \Delta_{\max}).$$

Шаг принимается лишь при $\rho > 0$. Гессиан при необходимости регуляризуется так же, как в методе Ньютона с выбором направления. Если радиус сжимается ниже 10^{-12} , дальнейший прогресс невозможен и метод останавливается со статусом «*малый радиус доверия*».

3.6 Квазиньютоновские методы: DFP, BFGS, L-BFGS

Квазиньютоновские методы строят приближение $H_k \approx H_f^{-1}$ только по разностям

$$s_k = x_{k+1} - x_k, \quad y_k = \nabla f(x_{k+1}) - \nabla f(x_k),$$

удовлетворяющим текущему уравнению $H_{k+1} y_k = s_k$. Обновление пары хранится только при $\langle s_k, y_k \rangle > 0$ (условие кривизны, гарантируемое Вольфе), что сохраняет $H_k \succ 0$ и, следовательно, направление спуска $p_k = -H_k g_k$.

DFP.

$$H_{k+1} = H_k + \frac{s_k s_k^\top}{\langle s_k, y_k \rangle} - \frac{H_k y_k y_k^\top H_k}{\langle y_k, H_k y_k \rangle}.$$

BFGS. С $\rho_k = 1 / \langle y_k, s_k \rangle$ и $V_k = I - \rho_k s_k y_k^\top$:

$$H_{k+1} = V_k H_k V_k^\top + \rho_k s_k s_k^\top.$$

BFGS, как правило, устойчивее DFP за счёт более удачной коррекции приближения.

L-BFGS. Матрица H_k явно не хранится: направление $-H_k g_k$ вычисляется *двухпетлевой рекурсией* по m последним парам (s_i, y_i) с начальным масштабированием $\gamma = \langle s_{k-1}, y_{k-1} \rangle / \langle y_{k-1}, y_{k-1} \rangle$. Затраты памяти $O(mn)$ вместо $O(n^2)$, что делает метод пригодным для больших n . Влияние m исследовано в задании 4.

3.7 Эталон: scipy Newton-CG

Newton-CG решает ньютоновскую систему *неточно*: на каждом внешнем шаге линейный CG приближённо находит p_k из $H_f p_k = -\nabla f$, не формируя H_f^{-1} . Метод используется как библиотечный эталон для сравнения.

4 Генератор квадратичных функций

Реализован генератор выпуклых квадратичных функций

$$f(x) = \frac{1}{2} \langle x, Ax \rangle - \langle b, x \rangle + c, \quad A = A^\top \succ 0,$$

с заданными размерностью n и числом обусловленности $k = \text{cond}(A)$. Схема генерации повторяет рекомендованную в условии:

1. собственные значения λ_i выбираются равномерно на $[1, k]$, причём $\lambda_{\min} = 1$, $\lambda_{\max} = k$, так что $\lambda_{\max}/\lambda_{\min} = k$;
2. генерируется случайная ортогональная матрица Q (QR-разложение гауссовой матрицы);
3. полагается $A = Q \Lambda Q^\top$ с $\Lambda = \text{diag}(\lambda_i)$;
4. выбирается точка минимума x^* и полагается $b = Ax^*$, $c = 0$.

Для каждой функции доступны $f(x)$, $\nabla f(x) = Ax - b$, $H_f(x) = A$ и точное решение x^* . Фиксация зерна генератора обеспечивает воспроизводимость экспериментов.

5 Тестовые функции

5.1 Функция Розенброка

$$f_R(x, y) = (1 - x)^2 + 100(y - x^2)^2, \quad x^* = (1, 1), \quad f_R(x^*) = 0.$$

Узкая параболическая долина («банан»); $\text{cond}(H_{f_R}(1, 1)) \approx 2500$ делает её тяжёлой для методов первого порядка.

5.2 Функция Химмельблау

$$f_H(x, y) = (x^2 + y - 11)^2 + (x + y^2 - 7)^2.$$

Четыре равнозначных глобальных минимума: $(3, 2)$, $(-2.805, 3.131)$, $(-3.779, -3.283)$, $(3.584, -1.848)$. Удобна для демонстрации зависимости результата от стартовой точки.

5.3 Функция Экли

$$f_A(x, y) = -20 \exp\left(-0.2 \sqrt{\frac{x^2 + y^2}{2}}\right) - \exp\left(\frac{\cos 2\pi x + \cos 2\pi y}{2}\right) + e + 20, \quad x^* = (0, 0).$$

Многоэкстремальная функция с бесчисленным множеством локальных минимумов на ребристых кольцах — жёсткий тест на устойчивость и на попадание в локальные минимумы. Градиент и гессиан Экли вычисляются численно (центральными разностями).

6 Экспериментальная часть

6.1 Задание 1: исследование на генераторе квадратичных функций


Рассмотрены размерности $n \in \{2, 10, 50, 100\}$ и числа обусловленности $k \in \{1, 10, 10^2, 10^3\}$. Для каждой пары (n, k) сгенерировано по две задачи с разными случайными матрицами, результаты усреднены. Стартовая точка $x_0 = (2.5, \dots, 2.5)^\top$, критерий $\|\nabla f\| \leq 10^{-8}$.

Таблица 1: Бенчмарк: среднее число итераций


n	k	CGq	FR	PR	NCh	NLs	DL	DFP	BFGS	LBFGS	sNCG
2	1	1	1	1	1	1	3	1	1	1	2
2	10	2	16	14	1	1	3	4	5	8	4
2	100	2	19	17	1	1	3	4	4	10	4
2	1000	2	36	16	1	1	3	2	3	12	4
10	1	1	1	1	1	1	4	1	1	1	2
10	10	10	23	26	1	1	4	18	18	20	12
10	100	10	45	47	1	1	4	15	15	31	13
10	1000	10	84	54	1	1	4	14	14	40	15
50	1	1	1	1	1	1	5	1	1	1	2
50	10	30	28	26	1	1	5	34	52	27	12
50	100	45	64	68	1	1	5	58	60	58	15
50	1000	48	106	152	1	1	5	57	57	78	19
100	1	1	1	1	1	1	6	1	1	1	2
100	10	34	28	27	1	1	6	36	54	30	12
100	100	63	67	72	1	1	6	99	116	74	18
100	1000	73	138	166	1	1	6	110	112	116	20

Зависимость от числа обусловленности k . Самое показательное наблюдение содержится в столбцах при фиксированном $n = 50$. Методы Ньютона (NCh, NLs) сходятся за **1 итерацию независимо от k** : на квадратичной функции ньютоновский шаг сразу попадает в минимум, а аффинная инвариантность делает метод нечувствительным к обусловленности. Линейный CG (CGq) укладывается в $\leq n$ итераций при любом k — это его свойство конечной сходимости. Напротив, нелинейные CG (FR, PR) и квазиньютоновские методы растут с ростом k : при $n = 50$ число итераций FR увеличивается с 28 ($k = 10$) до 106 ($k = 10^3$), что согласуется с оценкой $\sim \sqrt{\kappa}$. Dog Leg остаётся практически постоянным (4–5 шагов): для квадратичной модели ньютоновская точка точна, и после расширения радиуса метод сходится сразу.

Зависимость от размерности n . При фиксированном $k = 10$ методы Ньютона снова дают 1 итерацию при любом n , тогда как CGq, FR, PR и квазиньютоновские методы растут с n (для CG — линейно, как и предписывает теория конечной сходимости). Эталон **Newton-CG** занимает промежуточное положение: число внешних итераций невелико (2–20) и слабо растёт с k из-за увеличения числа внутренних CG-шагов.



(а) Зависимость от размерности n (при $k = 10$)



(б) Зависимость от обусловленности k (при $n = 50$)

Рис. 1: Число итераций методов на генераторе квадратичных функций (логарифмическая шкала по оси итераций). Методы Ньютона — горизонтальные линии на уровне 1 итерации; нелинейные CG и квазиньютоновские методы растут с n и k ; линейный CG ограничен размерностью n .

6.2 Задание 2: зависимость от начальной точки на 2D квадрате

Зафиксированы $n = 2$, $k = 10$, минимум перенесён в начало координат. Все методы запущены из пяти начальных точек, расположенных на разном расстоянии и в разных направлениях от минимума: $(-2, 2)$, $(2.5, 2.5)$, $(-2.5, -1)$, $(0.1, -2.5)$, $(3, -2)$.

Таблица 2: 2D квадратичная: сводка по 5 стартам

Метод	Итерации	f_calls	grad_calls	hess_calls	Сошлось
CG (квадратичный)	2	1	1	1	5/5
CG-FR	15	88	51	0	0/5
CG-PR	15	86	51	0	0/5
Ньютон (Холецкий)	1	1	2	1	5/5
Ньютон (поиск)	1	3	2	1	5/5
Dog Leg	3	7	4	3	5/5
DFP	4	12	9	0	5/5
BFGS	5	13	10	0	5/5
L-BFGS	9	23	20	0	1/5
Ньютон-CG (scipy)	3	3	3	3	5/5

Вывод. Усреднённые по пяти стартам показатели подтверждают картину задания 1: методы Ньютона и Dog Leg сходятся за единицы итераций из любой точки, BFGS/DFP — за 4–5, а нелинейные CG требуют около 15 шагов. Метки 0/5 и 1/5 у CG-FR, CG-PR и L-BFGS означают не ошибку, а остановку по *стагнации функции*: на 2D-квадратике методы доходят до точки на уровне машинного шума ($\|x - x^*\| \sim 10^{-8}$), где изменение f падает ниже разрешения `float64`, и строгий порог $\|\nabla f\| \leq 10^{-8}$ оказывается чуть за пределом достижимого. Траектории (рис. 2) наглядно показывают разницу геометрии: ньютоновские шаги идут прямо в минимум, а сопряжённые градиенты приходят за два сопряжённых направления.




Рис. 2: Траектории всех методов на линиях уровня 2D квадратичной функции ($k = 10$) из пяти различных начальных точек. Ньютоновские и квазиньютоновские методы идут к минимуму практически по прямой, сопряжённые градиенты — за два сопряжённых направления.

6.3 Задание 3: сложные нелинейные функции

Для каждой функции фиксируются найденная точка, значение функции, число итераций и число вычислений f , ∇f , H_f . Прочерк в столбце «Итерации» вместе с меткой $\times$ означает, что метод не достиг критерия $\|\nabla f\| \leq 10^{-8}$ (остановка по стагнации, лимиту итераций или неопределённости гессиана).

6.3.1 Розенброк, старт $(-1.2, 1.0)$

Таблица 3: Rosenbrock: старт $[-1.2 \ 1.]$

Метод	Итерации	f_calls	grad_calls	hess_calls	$f(x^*)$	Соплось
CG (квадратичный)	2	1	1	1	4.7319e+00	✓
CG-FR	—	1113	292	0	2.7195e-12	×
CG-PR	—	332	107	0	1.5712e-12	×
Ньютон (Холецкий)	6	1	7	6	3.4326e-20	✓
Ньютон (поиск)	21	50	22	21	3.7440e-21	✓
Dog Leg	24	49	25	24	8.5886e-22	✓
DFP	37	96	79	0	2.7289e-19	✓
BFGS	35	91	72	0	1.6883e-22	✓
L-BFGS	36	102	84	0	5.0141e-20	✓
Ньютон-CG (scipy)	85	107	107	85	1.3165e-19	✓

Вывод. Методы второго порядка уверенно проходят узкую долину: Ньютон по Холецкому — за 6 итераций, Dog Leg — за 24, метод Ньютона с выбором направления — за 21, квазиньютоновские методы — за 35–37. Линейный CG (CGq) к существенно неквадратичной функции неприменим: он делает один шаг по гессиану в стартовой точке и останавливается. Нелинейные CG доходят до значений $f \sim 10^{-12}$, но не дотягивают до строгого градиентного порога и помечаются как несошедшиеся по стагнации. Эталон `Newton-CG` сходится, но дорого по числу вычислений гессиана (85 вызовов).

6.3.2 Химмельблау, старт $(-2, 2)$

Таблица 4: Himmelblau: старт $[-2, 2]$

Метод	Итерации	f_calls	grad_calls	hess_calls	f(x*)	Сошлось
CG (квадратичный)	1	1	1	1	5.3363e+02	✓
CG-FR	—	73	23	0	1.8080e-17	×
CG-PR	—	119	38	0	2.1775e-17	×
Ньютон (Холецкий)	7	1	8	7	1.3647e-28	✓
Ньютон (поиск)	6	14	7	6	7.8886e-31	✓
Dog Leg	5	11	6	5	2.8175e-22	✓
DFP	11	34	24	0	1.6641e-19	✓
BFGS	10	33	22	0	2.4132e-19	✓
L-BFGS	9	24	19	0	3.2344e-22	✓
Ньютон-CG (scipy)	7	8	8	7	1.6379e-21	✓

Вывод. Из этой точки методы второго порядка и квазиньютоновские методы сходятся к ближайшему из четырёх минимумов за 5–11 итераций. Линейный CG приходит в минимум *квадратичной модели*, построенной в стартовой точке, а не в минимум самой функции Химмельблау (значение $f \approx 533$) — закономерное ограничение метода, рассчитанного только на квадратичные задачи. Нелинейные CG снова доходят до окрестности минимума ($f \sim 10^{-17}$), но останавливаются по стагнации, не выполнив строгий порог по градиенту.

6.3.3 Экли, старт $(1.5, 1.5)$

Таблица 5: Ackley: старт $[1.5, 1.5]$

Метод	Итерации	f_calls	grad_calls	hess_calls	f(x*)	Сошлось
CG (квадратичный)	—	1	1	1	7.5340e+00	×
CG-FR	—	207	41	0	4.4409e-16	×
CG-PR	—	207	39	0	4.4409e-16	×
Ньютон (Холецкий)	—	1	1	1	7.5340e+00	×
Ньютон (поиск)	5	30	6	5	3.5745e+00	✓
Dog Leg	—	59	30	29	3.5745e+00	×
DFP	—	92	24	0	4.4409e-16	×
BFGS	—	92	24	0	4.4409e-16	×
L-BFGS	—	92	24	0	4.4409e-16	×
Ньютон-CG (scipy)	4	24	24	4	5.6406e-09	✓

Случаи расходимости, локальных минимумов и остановки по ограничению. Экли — самый показательный тест, и здесь отдельно отмечены все аномальные исходы, требуемые заданием:

- **Неположительная определённость гессиана.** В точке $(1.5, 1.5)$ гессиан Экли не является положительно определённым. Поэтому метод Ньютона по Холецкому останавливается сразу (статус «гессиан не положительно определён»), а линейный CG — по неположительной кривизне. Это в точности предписанное условием поведение немодифицированного Ньютона.
- **Попадание в локальный минимум.** Метод Ньютона с выбором направления и Dog Leg сходятся в ближайший локальный минимум $(0.968, 0.968)$ с $f \approx 3.57$, а не в глобальный $(0, 0)$ — характерное свойство методов спуска на многоэкстремальной функции.
- **Остановка по стагнации.** Квазиньютоновские методы и нелинейные CG доходят до плоского участка ($f \approx 4.4 \cdot 10^{-16}$) и останавливаются по стагнации функции.
- **Эталон.** Newton-CG из этой точки находит окрестность глобального минимума ($f \approx 5.6 \cdot 10^{-9}$) за счёт внутреннего CG-решателя, сглаживающего шаг.




Рис. 3: Траектории методов на линиях уровня сложных функций. На Розенброке видно, как методы второго порядка проходят дно долины; на Химмельблау траектории расходятся к разным минимумам; на Экли часть методов застревает в локальном минимуме вблизи $(0.97, 0.97)$.

6.4 Задание 4: влияние размера памяти m в L-BFGS

Серия запусков L-BFGS на квадратичной задаче ($n = 50, k = 100, x_0 = (3, \dots, 3)^T$) при $m \in \{1, 2, 5, 10, 20, 50\}$.

Таблица 6: Влияние памяти m в L-BFGS ($n=50, k=100$)

m	Итерации	f_calls	grad_calls	Соплось
1	81	188	175	×
2	82	183	170	×
5	52	114	105	×
10	49	109	99	×
20	41	94	84	×
50	41	93	83	×

Вывод. Увеличение памяти m монотонно сокращает число итераций: с 81 при $m = 1$ до 41 при $m = 20$. Однако эффект быстро насыщается — переход от $m = 20$ к $m = 50$ (полная память при $n = 50$) уже не даёт выигрыша. Это типичное поведение L-BFGS: нескольких последних пар (s_i, y_i) достаточно, чтобы восстановить основную кривизну, а хранить всю историю (что эквивалентно BFGS) невыгодно по памяти. Практический компромисс $m = 5\text{--}10$ обеспечивает близкое к BFGS число итераций при затратах памяти $O(mn) \ll O(n^2)$. Метки $\times$ снова отражают остановку по стагнации на уровне машинного шума, а не сбой метода.




Рис. 4: Зависимость числа итераций L-BFGS от размера памяти m ($n = 50$, $k = 100$). Кривая быстро выходит на плато: после $m \approx 10$ дополнительная память почти не ускоряет метод.

7 Сравнительный анализ методов

Число итераций против суммарной стоимости. Малое число итераций не означает малой вычислительной стоимости. Методы Ньютона сходятся за 1 итерацию на квадратике, но каждая итерация требует вычисления и разложения гессиана ($O(n^3)$). Линейный CG не трогает H_f^{-1} вовсе и обходится одним вычислением A , но делает до n итераций. Квазиньютоновские методы не вычисляют гессиан совсем (столбцы H_f равны нулю), а платят несколькими вычислениями f и ∇f на шаг из-за Вольфе-поиска. Поэтому при сравнении методов нужно смотреть на все пять учётных столбцов одновременно, а не только на число итераций.

Влияние числа обусловленности.

- **Сопряжённые направления.** Линейный CG конечен ($\leq n$ шагов) при любом k , но фактическая скорость управляется $\sqrt{k}$. Нелинейные CG чувствительны к k : их число итераций растёт примерно как $\sqrt{k}$ (FR: $28 \rightarrow 106$ при росте k от 10 до 10^3).
- **Методы Ньютона.** Аффинно инвариантны: на квадратике дают 1 шаг *независимо* от k . Обусловленность влияет лишь на устойчивость разложения, но не на число итераций.
- **Квазиньютоновские методы.** Занимают промежуточное положение: накапливают информацию о кривизне за несколько итераций, поэтому зависят от k слабее, чем первопорядковые CG, но сильнее, чем Ньютон.

Требование положительной определённости гессиана.

- **Требуют $H_f \succ 0$:** немодифицированный Ньютон по Холецкому (иначе разложение невозможно — остановка со статусом) и линейный CG (иначе $p^\top Ap \leq 0$).
- **Устойчивы к нарушению:** Ньютон с выбором направления (регуляризация $H_f + \tau I$) и Dog Leg (доверительная область ограничивает шаг при невыпуклой модели).
- **Поддерживают $\succ 0$ по построению:** DFP, BFGS, L-BFGS сохраняют $H_k \succ 0$ при условии кривизны $\langle s_k, y_k \rangle > 0$, обеспечиваемом Вольфе, и потому всегда дают направление спуска.

Эксперимент с Экли в точке с неопределённым гессианом прямо иллюстрирует это разделение.

8 Общие выводы

1. **Квадратичные/выпуклые задачи.** Если гессиан доступен и положительно определён, метод Ньютона вне конкуренции (1 итерация, аффинная инвариантность). При больших n , когда $O(n^3)$ дорого, выгоднее линейный CG (нет работы с H_f^{-1}) или BFGS.
2. **Число обусловленности — ключевой параметр для первого порядка.** Нелинейные CG замедляются как $\sqrt{\kappa}$, тогда как методы Ньютона к κ нечувствительны. На плохо обусловленных задачах предпочтительны методы второго порядка и квазиньютоновские.
3. **Большая размерность.** L-BFGS даёт почти ту же скорость, что BFGS, при затратах памяти $O(mn)$; памяти $m = 5\text{--}10$ практически достаточно — кривая числа итераций выходит на плато.
4. **Сложные нелинейные функции.** Устойчивее всего ведут себя методы с защитой от невыпуклости: Ньютон с регуляризацией, Dog Leg и квазиньютоновские методы. Немодифицированный Ньютон по Холецкому останавливается на неоположительно определённом гессиане, а линейный CG применим лишь к квадратичным задачам.
5. **Многоэкстремальность и причины остановки.** На функции Экли разные методы приходят к разным исходам — глобальный минимум, локальный минимум, остановка по неопределённости гессиана или по стагнации. Единый формат результата с явной причиной остановки позволяет корректно различать эти случаи, что и требовалось в работе.